




BA Buenos
Aires
Ciudad

Agencia de Habilidades
para el Futuro

<Talent
Tech/>

DATA ANALYTICS

Clase 9 | Estadística Descriptiva

¡Les damos la bienvenida! 🚀

 **Vamos a comenzar a grabar la clase.**

Índice

Clase 09

Estadística Descriptiva

- Repaso y profundización: Estadística descriptiva.
 - Medidas de tendencia central.
 - Medidas de dispersión.

Clase 10

Exploración de Datos

- Técnicas de análisis exploratorio (EDA): visualización y resumen de datos

Objetivos de la Clase

- 1** Conocer algunas de las librerías de Python para estadística.
- 2** Repasar las Medidas de Tendencia Central y Medidas de Dispersión.
- 3** Aplicar Conceptos a Conjuntos de Datos: Relacionar las medidas estudiadas con ejemplos prácticos en Python, utilizando bibliotecas como Pandas y NumPy.

Librerías de Python para Estadísticas

Librerías de Python para Estadísticas

SciPy.stats

- Proporciona funciones para análisis estadísticos.
- Funciones incluyen distribuciones de probabilidad, pruebas estadísticas e intervalos de confianza.

Pandas

- Fundamental para manipulación y análisis de datos tabulares.
- Permite limpiar, transformar datos, y trabajar con series de tiempo.

Statsmodels

- Herramientas para análisis avanzados.
- Características: regresiones, modelos lineales, y análisis de series de tiempo.


Seaborn

- Visualización de datos estadísticos.
- Incluye gráficos de correlación, pruebas estadísticas, y estimaciones de densidad de kernel.

Medidas de Tendencia Central

Medidas de Tendencia Central

Las medidas de tendencia central son fundamentales para resumir un conjunto de datos.



Fuente: Allende H y Ahumada S, ILI-200

Medidas de Tendencia Central

Media

Suma de todos los valores dividida por la cantidad de valores.

Ejemplo en Python:

```
import numpy as np
notas = [4, 7, 5, 9, 6]
media = np.mean(notas)
print(f"La media es: {media}")
```

Mediana

Valor central de un conjunto de datos ordenados.

Ejemplo en Python:

```
mediana =
np.median(notas)
print(f"La mediana es: {mediana}")
```

Moda

Valor que aparece con mayor frecuencia en los datos.


Ejemplo en Python:

```
from scipy import stats
moda = stats.mode(notas)
[0]
print(f"La moda es:
```

{moda}")


Cuartiles y Percentiles

Son medidas estadísticas que nos ayudan a entender la distribución de un conjunto de datos. Son fundamentales para resumir la información y identificar patrones en los datos.



Cuartiles

- Dividen un conjunto de datos en **cuatro partes iguales**.
- Representados como Q_1 (25%), Q_2 (50% - Mediana) y Q_3 (75%).



Ejemplo de Cuartiles

Supongamos que tenemos el siguiente conjunto de datos que representa las puntuaciones de un grupo de alumnos en un examen:

56,74,68,82,90,62,78,84,88,95,56,74,68,82,90,62,78,84,88,95

Para calcular los cuartiles de este conjunto de datos, primero debemos ordenarlos:

56,56,62,62,68,68,74,74,78,78,82,82,84,84,88,88,90,90,95,95

Cuartiles:

- **Q1** sería el valor en el 25% de los datos, que en este caso es **68**.
- **Q2** o mediana sería **78**.
- **Q3** sería **88**.

Cálculo de Cuartiles en Python

```
import numpy as np

# Datos de puntuaciones
puntuaciones =
[56,74,68,82,90,62,78,84,88,95,56,74,68,
82,90,62,78,84,88,95]

# Cálculo de cuartiles
Q1 = np.percentile(puntuaciones, 25)
Q2 = np.percentile(puntuaciones, 50) #
Mediana
Q3 = np.percentile(puntuaciones, 75)

print(f"Primer cuartil (Q1): {Q1}")
print(f"Segundo cuartil (Q2 - Mediana):
{Q2}")
print(f"Tercer cuartil (Q3): {Q3}")
```

- ❖ Con estos datos, podemos observar que el 25% de los alumnos obtuvo menos de 68 puntos, el 50% menos de 78, y el 75% menos de 88.

Rango Intercuartil

El RIC (o IQR) es una **medida de la dispersión de la mitad central de un conjunto de datos**. Se calcula restando el primer cuartil ($Q1$) del tercer cuartil ($Q3$).

- Es una medida de variabilidad.
- Es una buena medida de dispersión para distribuciones sesgadas.
- Se puede visualizar claramente mediante el cuadro en un diagrama de caja.

Usos del IQR

- Es la mejor medida de variabilidad para distribuciones asimétricas o conjuntos de datos con valores atípicos.
- Se utiliza para detectar valores atípicos.

Cálculo del IQR

- El IQR se calcula con la fórmula: $IQR = Q3 - Q1$.

BoxPlot

Un boxplot, también conocido como **diagrama de caja y bigotes**, es un gráfico que muestra cómo se distribuyen los datos numéricos.

- Muestra la mediana y los cuartiles de los datos
- Identifica valores atípicos
- Permite intuir la morfología y simetría de los datos
- Se puede dibujar más de un diagrama de caja por gráfico

Componentes:


- **Cajas:** Representan el rango intercuartílico (IQR) de los datos
- **Bigotes:** Son líneas que se extienden desde ambos extremos de la caja.
- **Valores atípicos:** Son puntos fuera de los bigotes considerados inusuales o extremos
- **Gorros:** Son líneas perpendiculares en los extremos de los bigotes






BoxPlot

Usos

- Es ideal para comparar distribuciones entre grupos
- Es una forma estandarizada para representar gráficamente una serie de datos numéricos
- Es una forma útil de comparar diferentes conjuntos de



BoxPlot



¿Qué son los Percentiles?

- Dividen un conjunto de datos en 100 partes iguales.
- Indican el valor bajo el cual se encuentra un cierto porcentaje de los datos.




Ejemplo de Percentiles

Usando el mismo **conjunto de datos**:

56,62,68,74,78,82,84,88,90,95
56,62,68,74,78,82,84,88,90,95

- **Percentiles:**

- $P_{25}=68$
- $P_{50}=78$ (Mediana)
- $P_{75}=88$




Cálculo de Percentiles en Python

```
P25 = np.percentile(puntuaciones, 25)
P50 = np.percentile(puntuaciones, 50) # Mediana
P75 = np.percentile(puntuaciones, 75)
print(f"P25: {P25}, P50: {P50}, P75: {P75}")
```


¿Por qué son Importantes?

- Resumen efectivo de datasets.
- Identificación de outliers y variabilidad.
- Ayuda en la toma de decisiones informadas.



Medidas de Dispersión

Medidas de Dispersión



Medidas de Dispersión

Las medidas de dispersión indican la variabilidad de los datos

Rango

Diferencia entre el valor máximo y mínimo.

Ejemplo en Python:

```
rango = np.max(notas) -  
np.min(notas)  
print(f"El rango es:  
{rango}")
```

Varianza

Mide la dispersión respecto a la media.

Ejemplo en Python:

```
varianza = np.var(notas)  
  
print(f"La varianza es:  
{varianza}")
```

Desviación standard


Raíz cuadrada de la varianza.

Ejemplo en Python:

```
desviacion_estandar =  
np.std(notas)  
  
print(f"La desviación estándar  
es: {desviacion_estandar}")
```


Reflexión final

En esta clase, revisamos conceptos clave de la estadística descriptiva. Al comprender estos fundamentos, tus habilidades en data analytics se verán fortalecidas, permitiéndote realizar un análisis más profundo y significativo de conjuntos de datos.





Ejercicios Prácticos

Ejercicios Prácticos

Obligatorio



Actividad 1: Análisis de Tendencia Central

Objetivo:

- Calcular la media, la mediana y la moda de las ventas mensuales.
- Comprender la importancia de estas medidas en el análisis de datos de ventas.

Contexto

En esta nueva semana de pasantía en SynthData. Silvia, la Project Manager y Data Scientist, te acaba de asignar una tarea crucial para conocer mejor los datos de clientes que la empresa ha recopilado. Tenés que calcular las medidas de tendencia central de las ventas mensuales de un producto específico en el último año. Esto les ayudará a identificar patrones y tomar decisiones informadas sobre el inventario.

Ejercicios Prácticos

Consigna:

Realizá los siguientes **cálculos en Python** con los datos sobre las ventas mensuales en unidades del último año:

1. Calcular la media de las ventas.
2. Calcular la mediana de las ventas.
3. Calcular la moda de las ventas.

Interpretá y explicá que significan estos valores.

Obligatorio



¿Por qué importa esto en SynthData?

Las medidas de tendencia central son esenciales para entender el rendimiento de un producto en el mercado. Ayudan a identificar si las ventas están creciendo, estables o en declive, permitiendo tomar decisiones estratégicas para el negocio.

Ejercicios Prácticos

Obligatorio



Actividad 2: Medidas de Dispersión

Objetivo:

- Calcular el rango, la varianza y la desviación standard de las ventas mensuales.
- Reconocer cómo estas medidas de dispersión informan sobre la estabilidad de las ventas.

Contexto

Matías, el Data Analyst, te solicita que analices la variabilidad de las ventas mensuales que calculaste en la actividad anterior. Este análisis es fundamental para saber si las fluctuaciones en las ventas podrían afectar los pronósticos futuros. Así, podrás entender mejor el comportamiento del producto en distintos meses del año.

Ejercicios Prácticos

Consigna:

Utiliza el mismo conjunto de datos de ventas mensuales del ejercicio anterior y realiza lo siguiente en Python:

1. Calcular el rango de las ventas.
2. Calcular la varianza de las ventas.
3. Calcular la desviación standard de las ventas.

Obligatorio



Teorizá a partir de las dos actividades: Si tuvieras que adivinar de qué producto se trata, cuál crees que se ajusta más a los valores obtenidos? Justificá tu elección.

- ☐ Leche
- ☐ Bufanda
- ☐ Árbol de navidad
- ☐ Kit de geometría escolar
- ☐ Bronceador

Ejercicios Prácticos

Obligatorio



¿Por qué importa esto en SynthData?

Las medidas de dispersión son esenciales para evaluar el riesgo y la estabilidad de las ventas. Un alto rango, varianza o desviación standard puede indicar comportamientos erráticos, lo que podría afectar la planificación del inventario y ventas futuras.

Ejercicios Prácticos



- ❗ Estos ejercicios son una simulación de cómo se podría resolver el problema **en este contexto específico**. Las soluciones encontradas no aplican de ninguna manera a todos los casos.

Recuerda que las soluciones dependerán de los sets de datos, el contexto y los requerimientos específicos de los stakeholders y las organizaciones.

¡Gracias!

